

MINI PROJECT

MATEMATIKA SAINS DATA

Regresi Linier dan Parabolik

Nama Anggota : Nazla Aliza Pasya (2510514002)
Annidya Nazwa Chiloschista (2510514013)
Kelas : A
Prodi : Sains Data
Tema Dataset : Curah Hujan dan Hasil Panen

1. PENDAHULUAN

1.1 Latar Belakang

Sektor pertanian merupakan salah satu sektor vital yang mempengaruhi ketahanan pangan suatu negara. Salah satu faktor lingkungan yang paling berpengaruh terhadap produktivitas tanaman adalah curah hujan. Secara teoritis, hubungan antara curah hujan dan hasil panen bersifat non linier yaitu kekurangan air menyebabkan kekeringan, sedangkan kelebihan air dapat menyebabkan banjir dan kerusakan pada akar.

Proyek mini ini mengimplementasikan regresi linier dan parabolik pada dataset nyata multi negara dari Kaggle untuk menganalisis hubungan curah hujan tahunan (mm) dengan hasil panen padi (ton/ha). Hasil analisis menunjukkan bahwa R^2 kedua model tergolong rendah, yang merupakan temuan penting. Hal ini mencerminkan keterbatasan model univariat pada data multi negara yang sangat heterogen.

1.2 Rumusan Masalah

1. Bagaimana hubungan antara curah hujan (mm) dan hasil panen padi (ton/ha) secara global?
2. Model manakan yang lebih baik? Regresi linier atau regresi parabolik?
3. Apa implikasi dari nilai R^2 yang rendah terhadap validitas model?

1.3 Tujuan

1. Mengimplementasikan regresi linier dan parabolik pada data nyata dari Kaggle
2. Membandingkan performa kedua model menggunakan R^2 , RMSE, dan MAE

3. Menginterpretasikan keterbatasan model univariat pada heterogen global

1.4 Dataset

Dataset yang digunakan adalah Crop Yield Prediction dari Kaggle (Rish Patel), berisi data hasil panen berbagai komoditas dari berbagai negara. File utama: yield_df.csv dengan kolom average_rain_fall_mm_per_year dan hg/ha_yield, dengan data awal rainfall: 5.6717 dan data yield: 6.727. Kemudian di filter dan dibersihkan menghasilkan 2.883 (khusus item rice, paddy) baris siap dianalisis.

2. EKSPLORASI DATA (EDA)

2.1 Statistik Deskriptif

Setelah proses filtering dan cleaning outlier, diperoleh 2.883 baris data bersih:

Statistik	Rainfall (mm)	Value (ton/ha)
Mean	1338,352064	3,379855983
Median	1187	3,0004
Standar deviasi	824,5216458	1,860051821


Perhitungan MATLAB:

```
Statistik Deskriptif Variabel X (Curah Hujan):
Mean   : 1338.35 mm
Median : 1187.00 mm
Std Dev: 824.66 mm
Statistik Deskriptif Variabel Y (Hasil Panen Rice, paddy):
Mean   : 3.38 Ton/ha
Median : 3.00 Ton/ha
Std Dev: 1.86 Ton/ha
```


Variasi curah hujan sangat tinggi (std = 824,66 mm) karena dataset mencakup negara-negara dari berbagai iklim, mulai dari kawasan semi-arid hingga tropis basah. Demikian pula yield memiliki sebaran luas (std = 1,86 ton/ha), yang mencerminkan perbedaan teknologi pertanian antar negara.

2.2 Visualisasi

Visualisasi scatter plot dengan excel:



Visualisasi scatter plot dengan MATLAB:



Scatter plot X (rainfall) vs Y (value) menunjukkan sebaran data yang sangat lebar dan tidak membentuk pola yang kuat secara visual. Hal ini sudah mengindikasikan bahwa curah hujan tahunan saja tidak cukup sebagai prediktor tunggal hasil panen padi dalam skala global. Titik- titik data tersebar dari rainfall 51 mm hingga 3.240 mm dengan yield berkisar antara 0,20 hingga 8,40 ton/ha, mencerminkan heterogenitas kondisi pertanian dari 101 negara yang sangat berbeda dalam hal teknologi, infrastruktur irigasi, dan kebijakan pertanian.

Kurva regresi linier (merah putus-putus) dan parabolik (biru) keduanya hampir mendatar, yang konsisten dengan nilai R^2 yang rendah. Meskipun demikian, kurva parabolik membuka ke atas (U) dengan titik minimum di sekitar $x = 1.707$ mm, menunjukkan adanya komponen non linier kecil dalam hubungan kedua variabel ini. Model parabolik secara konsisten unggul dibanding model linier pada seluruh metrik evaluasi ($R^2 = 0,0064$ vs $0,0011$; RMSE = 1,6537 vs 1,6581 ton/ha).

3. PERHITUNGAN MANUAL

3.1 Sampel Data ($n=15$)

Berikut 15 sampel data representatif yang diambil secara sistematis dari dataset bersih:

No	X (mm)	Y (ton/ha)	X^2	X^3	X^4	XY	X^2Y
1	327	2,2482	106929	34965783	11433811041	735,1614	240397,7778
2	1485	4	2205225	3274759125	4,86302...	5940	8820900
3	89	2,6667	7921	704969	62742241	237,3363	21122,9307
4	1010	0,8333	1020100	1030301000	1,0406...	841,633	850049,33
5	591	3,6782	349281	206425071	1,21997...	2173,8162	1284725,374
6	534	7,0936	285156	152273304	81313944336	3787,9824	2022782,553
7	447	0,7292	199809	89314623	39923636481	325,9524	145700,7228
8	2666	2,1693	7107556	18948744296	5,05174...	5783,3538	15418421,23
9	1705	2,2749	2907025	4956477625	8,45079...	3878,7045	6613191,173
10	1039	1,2783	1079521	1121622319	1,16537...	1328,1537	1379951,694
11	2200	1,9375	4840000	10648000000	2,34256...	4262,5	937750
12	1761	1,8980	3101121	5461074081	9,61695...	3342,378	5885925,658
13	2722	1,2394	7409284	20168071048	5,48975...	3373,6468	9183066,32
14	608	4,2464	369664	224755712	1,36651...	2581,8112	1569741,21
15	748	1,8144	559504	418508992	3,13045...	1357,1712	1015164,058
Σ	17932	38,1074	31548096	66735997948	1,54682...	39949,6009	63828642,35

3.2 Persamaan Normal - Regresi Linier

$$\begin{aligned}\sum x &= 17932 \\ \sum y &= 38,1074 \\ \sum x^2 &= 31548096 \\ \sum x^3 &= 66735997948 \\ \sum x^4 &= 154681601943096 \\ \sum xy &= 39949,6009 \\ \sum x^2y &= 63828642,3495\end{aligned}$$

1) Linear

$$\begin{aligned}b &= \frac{(n \text{ sampel} \cdot \sum xy) - (\sum x \cdot \sum y)}{(n \text{ sampel} \cdot \sum x^2) - (\sum x)^2} & a &= \bar{y} - b \cdot \bar{x} \\ &= \frac{(15 \cdot 39949,6009) - (17932 \cdot 38,1074)}{(15 \cdot 31548096) - (17932)^2} & &= 2,540493333 - (-0,000554498) \cdot 1195,166667 \\ &= \frac{599244,9035 - 689444,4448}{158221440 - 321562624} & &= 3,203377573 \\ &= -0,000554498\end{aligned}$$

$$\therefore y = a + bx \rightarrow y = 3,203377573 - 0,000554498x //$$

3.3 Persamaan Normal - Regresi Parabolik

2) Parabolik

$$\begin{aligned}\sum y &= n \text{ sampel} \cdot a + b \cdot \sum x + c \cdot \sum x^2 \rightarrow 38,1074 = 15a + 17932b + 31548096c \\ \sum xy &= a \cdot \sum x + b \cdot \sum x^2 + c \cdot \sum x^3 \rightarrow 39949,6009 = 17932a + 31548096b + 66735997948c \\ \sum x^2y &= a \cdot \sum x^2 + b \cdot \sum x^3 + c \cdot \sum x^4 \\ &\rightarrow 63828642,3495 = 31548096a + 66735997948b + 154681601943096c\end{aligned}$$

Matriks (3x3)

$$\begin{bmatrix} 15 & 17932 & 31548096 \\ 17932 & 31548096 & 66735997948 \\ 31548096 & 66735997948 & 154681601943096 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 38,1074 \\ 39949,6009 \\ 63828642,3495 \end{bmatrix}$$

$$\det \approx 1,70188 \times 10^{23} \text{ (menggunakan kalkulator matriks)}$$

$$D_a = \begin{vmatrix} 38,1074 & 17932 & 31548096 \\ 39949,6009 & 31548096 & 66735997948 \\ 63828642,3495 & 66735997948 & 154681601943096 \end{vmatrix}$$

$$\approx 5,35002 \times 10^{23}$$

$$a = \frac{D_a}{\det} = \frac{5,35002 \times 10^{23}}{1,70188 \times 10^{23}} = 3,1435$$

$$D_b = \begin{vmatrix} 15 & 38,1074 & 31548096 \\ 17932 & 39949,6009 & 66735997948 \\ 31548096 & 63828642,3495 & 154681601943096 \end{vmatrix}$$

$$\approx -7,23429 \times 10^{19}$$

$$b = \frac{D_b}{\det} = \frac{-7,23429 \times 10^{19}}{1,70188 \times 10^{23}} = -0,0004251$$

$$D_c = \begin{vmatrix} 15 & 17932 & 38,1074 \\ 17932 & 31548096 & 39949,6009 \\ 31548096 & 66735997948 & 63828642,3495 \end{vmatrix}$$

$$\approx -7,67393 \times 10^{15}$$

$$c = \frac{D_c}{\det} = \frac{-7,67393 \times 10^{15}}{1,70188 \times 10^{23}} = -4,5091 \times 10^{-8}$$

$$\therefore y = a + bx + cx^2 \rightarrow y = 3,1435 - 0,0004251x - 4,5091 \times 10^{-8} //$$

4. IMPLEMENTASI MATLAB

4.1 Script

```

1 % ANALISIS HUBUNGAN CURAH HUJAN & HASIL PANEN (RICE, PADDY)
2 clear; clc; close all;
3
4 %% Membersihkan Dataset dan Eksplorasi Data (EDA)
5
6 fprintf('      Membersihkan Dataset dan Eksplorasi Data (EDA)      \n');
7
8 % 1. Import file dari folder
9 if ~exist('rainfall.csv', 'file') || ~exist('yield.csv', 'file')
10     error('Error: File "rainfall.csv" atau "yield.csv" tidak ditemukan di folder ini!');
11 end
12
13 % 2. Membaca file CSV yang sudah diimport
14 opts_rain = detectImportOptions('rainfall.csv', 'TextType', 'string');
15 opts_yield = detectImportOptions('yield.csv', 'TextType', 'string');
16 df_rain = readtable('rainfall.csv', opts_rain);
17 df_yield = readtable('yield.csv', opts_yield);
18
19 % 3. Normalisasi nama kolom (menghilangkan spasi tak sengaja di awal/akhir nama kolom)
20 df_rain.Properties.VariableNames = strtrim(df_rain.Properties.VariableNames);
21 df_yield.Properties.VariableNames = strtrim(df_yield.Properties.VariableNames);
22
23 % 4. Pembersihan data rainfall (mengonversi '.' menjadi NaN dan menghapusnya)
24 if ~isnumeric(df_rain.average_rain_fall_mm_per_year)
25     df_rain.average_rain_fall_mm_per_year = str2double(df_rain.average_rain_fall_mm_per_year);
26 end
27 df_rain(isnan(df_rain.average_rain_fall_mm_per_year), :) = [];
28

```

Import dataset, preprocessing, dan EDA

```
29 % 5. Penggabungan dataset yield dan rainfall berdasarkan kesamaan kolom area dan year
30 merged_data = innerjoin(df_yield, df_rain, 'Keys', {'Area', 'Year'});
31
32 % Filtering data untuk mengecek korelasi curah hujan dengan satu jenis tanaman
33 pilih_tanaman = 'Rice, paddy';
34
35 if ~strcmpi(pilih_tanaman, 'All')
36     merged_data = merged_data(strcmpi(merged_data.Item, pilih_tanaman), :);
37     fprintf('Menyaring data khusus untuk komoditas: %s\n', pilih_tanaman);
38 end
39
40 % Menentukan Variabel X dan Y
41 X = merged_data.average_rain_fall_mm_per_year; % X = Curah hujan (mm)
42 Y = merged_data.Value / 10000; % Y = Hasil panen diubah dari hg/ha menjadi Ton/ha
43
44 % 6. Perhitungan Statistik Deskriptif
45 fprintf('\nStatistik Deskriptif Variabel X (Curah Hujan):\n');
46 fprintf(' Mean   : %.2f mm\n Median : %.2f mm\n Std Dev: %.2f mm\n', mean(X), median(X), std(X));
47 fprintf('Statistik Deskriptif Variabel Y (Hasil Panen %s):\n', pilih_tanaman);
48 fprintf(' Mean   : %.2f Ton/ha\n Median : %.2f Ton/ha\n Std Dev: %.2f Ton/ha\n', mean(Y), median(Y), std(Y));
49
50 % 7. Deteksi outliers menggunakan Metode IQR pada Variabel Y
51 Q1 = prctile(Y, 25); Q3 = prctile(Y, 75); IQR_val = Q3 - Q1;
52 batas_bawah = Q1 - 1.5 * IQR_val; batas_atas = Q3 + 1.5 * IQR_val;
53 outliers = (Y < batas_bawah) | (Y > batas_atas);
54 fprintf('Analisis Outlier Data: Jumlah data outliers terdeteksi: %d dari %d data.\n', sum(outliers), length(Y));
55
56 % 8. Pembuatan Scatter Plot
57 figure('Name', 'Tahap 01: Scatter Plot Hasil Join Data', 'NumberTitle', 'off');
58 scatter(X, Y, 25, 'filled', 'MarkerFaceColor', [0.1 0.6 0.4], 'MarkerEdgeColor', 'none');
59 grid on; hold on;
60 title(['Scatter Plot Data Riil: Curah Hujan vs Hasil Panen (', pilih_tanaman, ')']);
61 xlabel('Curah Hujan Tahunan (mm)'); ylabel('Hasil Panen (Ton/ha)');
```

Preprocessing, EDA, dan pembuatan scatter plot

```
63 %% Pemilihan dan Justifikasi Model
64 fprintf('\nModel regresi yang digunakan untuk dataset ini adalah regresi parabolik\n');
65
66 %% Implementasi Perhitungan Persamaan Normalisasi
67
68 fprintf('          \nPerhitungan Persamaan Normalisasi          \n');
69
70 % Pembagian Data: 80% Training Set & 20% Testing Set
71 rng(10); % Mengunci keacakan agar hasil konsisten saat dijalankan ulang
72 n_total = length(X);
73 porsi_train = 0.8;
74 idx_acak = randperm(n_total);
75 idx_train = idx_acak(1:round(porsi_train * n_total));
76 idx_test = idx_acak(round(porsi_train * n_total) + 1:end);
77
78 X_train = X(idx_train); Y_train = Y(idx_train);
79 X_test = X(idx_test);   Y_test = Y(idx_test);
80
81 % Perhitungan sigma
82 n_tr = length(X_train);
83 s_x = sum(X_train);      s_x2 = sum(X_train.^2);
84 s_x3 = sum(X_train.^3);  s_x4 = sum(X_train.^4);
85 s_y = sum(Y_train);      s_xy = sum(X_train .* Y_train); s_x2y = sum((X_train.^2) .* Y_train);
```

Justifikasi model parabolik dan perhitungan normalisasi

```
87 % Matriks Normal untuk Model Parabolik (Derajat 2)
88 Matriks_A_Para = [n_tr, s_x, s_x2; ...
89                  s_x, s_x2, s_x3; ...
90                  s_x2, s_x3, s_x4];
91 Matriks_B_Para = [s_y; s_xy; s_x2y];
92 coef_manual = Matriks_A_Para \ Matriks_B_Para; % Menyelesaikan persamaan [a; b; c]
93
94 % Toolbox dan utility MATLAB
95 p_lin_matlab = polyfit(X_train, Y_train, 1); % Model Linier bawaan
96 p_para_matlab = polyfit(X_train, Y_train, 2); % Model Parabolik bawaan
97
98 fprintf('Validasi hasil komputasi ')
99 fprintf('Validasi Hasil Komputasi Koefisien Kuadratik:\n');
100 fprintf(' -> Hasil Rumus Manual : a = %7.4f, b = %7.4f, c = %7.6f\n', coef_manual(1), coef_manual(2), coef_manual(3));
101 fprintf(' -> Hasil Utility MATLAB: a = %7.4f, b = %7.4f, c = %7.6f\n', p_para_matlab(3), p_para_matlab(2), p_para_matlab(1));
102
```

Perhitungan normalisasi untuk model parabolik

```

103 %% Evaluasi Model dan Uji Data Test
104
105 fprintf('          Evaluasi Model          \n');
106
107 % Prediksi menggunakan data uji (Test Set)
108 Y_pred_lin = polyval(p_lin_matlab, X_test);
109 Y_pred_para = polyval(p_para_matlab, X_test);
110
111 % Metrik Performa Model Linier
112 mae_lin = mean(abs(Y_test - Y_pred_lin));
113 rmse_lin = sqrt(mean((Y_test - Y_pred_lin).^2));
114 r2_lin = 1 - (sum((Y_test - Y_pred_lin).^2) / sum((Y_test - mean(Y_test)).^2));
115
116 % Metrik Performa Model Parabolik
117 mae_para = mean(abs(Y_test - Y_pred_para));
118 rmse_para = sqrt(mean((Y_test - Y_pred_para).^2));
119 r2_para = 1 - (sum((Y_test - Y_pred_para).^2) / sum((Y_test - mean(Y_test)).^2));
120
121 % Menampilkan Tabel Perbandingan Evaluasi
122 fprintf('TABEL PERBANDINGAN PERFORMA (PADA DATA UJI):\n');
123 fprintf('-----\n');
124 fprintf('Metrik Evaluasi | Model Linier | Model Parabolik\n');
125 fprintf('-----\n');
126 fprintf('MAE (Sifat Error) | %7.4f | %7.4f\n', mae_lin, mae_para);
127 fprintf('RMSE (Akurasi) | %7.4f | %7.4f\n', rmse_lin, rmse_para);
128 fprintf('R-Square (R2) | %7.4f | %7.4f\n', r2_lin, r2_para);
129 fprintf('-----\n');
130
131 % Visualisasi Kurva Fitting Terbaik
132 X_domain = linspace(min(X), max(X), 1000);
133 plot(X_domain, polyval(p_lin_matlab, X_domain), 'r--', 'LineWidth', 2);
134 plot(X_domain, polyval(p_para_matlab, X_domain), 'b-', 'LineWidth', 2.5); % Mengubah warna garis parabolik menjadi biru
135 legend('Data Aktual Padi', 'Tren Garis Linier', 'Tren Parabolik Kuadratik', 'Location', 'Best');
136

```

Evaluasi model

```

137 % Grafik Analisis Galat (Residual Plot) Model Parabolik
138 figure('Name', 'Tahap 04: Grafik Analisis Galat Residual', 'NumberTitle', 'off');
139 stem(X_test, Y_test - Y_pred_para, 'filled', 'Color', [0.2 0.5 0.3]);
140 hold on; yline(0, 'k-', 'LineWidth', 1.5); grid on;
141 title(['Plot Sisaan Galat (Residual Plot) Model Parabolik - ', pilih_tanaman]);
142 xlabel('Curah Hujan (mm)'); ylabel('Sisaan Error (Ton/ha)');
143

```

Visualisasi model

```

144 %% Interpretasi hasil
145 fprintf('          Interpretasi Hasil          \n');
146
147 c_opt = p_para_matlab(1);
148 b_opt = p_para_matlab(2);
149 a_opt = p_para_matlab(3);
150
151 % Menghitung titik puncak kurva parabolik (Vertex)
152 X_optimal = -b_opt / (2 * c_opt);
153 Y_maksimal = polyval(p_para_matlab, X_optimal);
154
155 fprintf('Persamaan Matematika Hasil Pemodelan Parabolik (%s):\n', pilih_tanaman);
156 fprintf(' Y = (%.4e)X^2 + (%.4f)X + (%.4f)\n\n', c_opt, b_opt, a_opt);
157 fprintf('HASIL ANALISIS TITIK PUNCAK OPTIMAL:\n');
158 fprintf(' -> Rekomendasi Curah Hujan Optimal : %.2f mm/tahun\n', X_optimal);
159 fprintf(' -> Estimasi Hasil Panen Maksimum : %.2f Ton/ha\n', Y_maksimal);

```

Substitusi persamaan untuk interpretasi

4.2 Output

```
Command Window
Memeriksa Dataset dan Eksplorasi Data (EDA)
Warning: Column headers from the file were modified to make them valid
MATLAB identifiers before creating variable names for the table. The
original column headers are saved in the VariableDescriptions property.
Set 'VariableNamingRule' to 'preserve' to use the original column headers
as table variable names.
Menyaring data khusus untuk komoditas: Rice, paddy

Statistik Deskriptif Variabel X (Curah Hujan):
    Mean : 1338.35 mm
    Median : 1187.00 mm
    Std Dev: 824.66 mm
Statistik Deskriptif Variabel Y (Hasil Panen Rice, paddy):
    Mean : 3.38 Ton/ha
    Median : 3.00 Ton/ha
    Std Dev: 1.86 Ton/ha

Analisis Outlier Data:
    Jumlah data outliers terdeteksi: 58 dari 2883 data.



Model regresi yang digunakan untuk dataset ini adalah regresi parabolik

Perhitungan Persamaan Normalisasi
Validasi hasil komputasi Validasi Hasil Komputasi Koefisien Kuadratik:
    -> Hasil Rumus Manual : a = 4.2613, b = -0.0011, c = 0.000000
    -> Hasil Utility MATLAB: a = 4.2613, b = -0.0011, c = 0.000000

Evaluasi Model
TABEL PERBANDINGAN PERFORMA (PADA DATA UJI):
-----
Metrik Evaluasi | Model Linier | Model Parabolik
-----
MAE (Sifat Error) | 1.5418 | 1.5173
RMSE (Akurasi) | 1.9107 | 1.8949
R-Square (R2) | 0.0239 | 0.0400
-----

Interpretasi Hasil
Persamaan Matematika Hasil Pemodelan Parabolik (Rice, paddy):
    Y = (2.2828e-07)X^2 + (-0.0011)X + (4.2613)

HASIL ANALISIS TITIK PUNCAK OPTIMAL:
    -> Rekomendasi Curah Hujan Optimal : 2335.92 mm/tahun
    -> Estimasi Hasil Panen Maksimum : 3.02 Ton/ha
```




5. EVALUASI MODEL

5.1 RMSE

RMSE berfungsi untuk mengukur rata-rata dari penyimpangan antara hasil panen yang diprediksi dengan data hasil panen yang sebenarnya. Berdasarkan perhitungan yang dilakukan dengan MATLAB, hasil RMSE untuk model paraboliknya adalah 1,8949 yang mana angka tersebut lebih kecil daripada hasil RMSE model linear sebesar 1,9107. Hasil tersebut menandakan bahwa model parabolik lebih akurat dibandingkan dengan model linear untuk pengolahan dataset ini.

5.2 Residual Plot



Residual di sini adalah selisih antara data aktual dengan garis prediksi. Pola residual pada model linear membentuk plot lengkungan sistematis yang menandakan adanya ketidaktepatan dengan sifat asli data, sehingga model linear kurang tepat untuk digunakan. Sementara itu, pada model parabolik titik-titik residualnya lebih tersebar di atas garis 0 tanpa membentuk pola yang kentara.

Titik yang berada di atas garis 0 menandakan under-prediction, sedangkan yang berada di bawah garis 0 menandakan over-prediction. Selain itu, residual plot yang ada memudahkan untuk melihat outlier yang ada di alam dataset. Titik yang berada jauh di atas kumpulan titik lainnya dan menjauhi garis 0 merupakan outlier dari dataset yang digunakan

5.1 R^2

Berdasarkan hasil perhitungan MATLAB, didapatkan nilai R-square model linear sebesar 0,0239 dan R-square model parabolik sebesar 0,0400. Angka R-square model parabolik lebih besar daripada milik model linear. Dengan demikian, model parabolik

memiliki angka R-square yang lebih besar dibandingkan dengan model linear. Hal ini membuktikan bahwa model parabolik lebih dapat memperlihatkan hasil korelasi yang kuat antara curah hujan dengan hasil panen.

6. INTERPRETASI DAN KESIMPULAN

6.1 Mengapa R^2 sangat Rendah?

R-square yang didapatkan sangat rendah karena pada pelaksanaan sebenarnya, hasil pertanian tidak hanya dipengaruhi oleh besaran curah hujan, melainkan juga dari faktor lainnya seperti kualitas tanah dan pupuk yang digunakan, serta sinar matahari yang memadai berdasarkan kondisi sebenarnya.

6.2 Perbandingan Kedua Model

Berdasarkan hasil evaluasi menggunakan tiga metrik utama, model parabolik secara konsisten mengungguli model linier pada seluruh indikator:

Metrik	Regresi Linier	Regresi Parabolik	Keterangan
R^2	0,0239	0,0400	Parabolik lebih tinggi
RMSE (ton/ha)	1,9107	1,8949	Parabolik lebih kecil
MAE (ton/ha)	1,5418	1,5173	Parabolik lebih kecil

Meskipun selisih antar kedua model relatif kecil, konsistensi keunggulan model parabolik di semua metrik mengonfirmasi bahwa hubungan curah hujan dengan hasil panen memiliki komponen non linier. Kurva parabolik yang membuka ke atas (U) menunjukkan bahwa model ini lebih mampu menangkap pola data dibandingkan garis lurus, meskipun kemampuan prediksinya secara keseluruhan masih terbatas akibat heterogenitas data multi negara.

6.3 Interpretasi Titik Optimal

Titik optimal berdasarkan perhitungan otomatis dengan MATLAB didapatkan dengan melakukan perhitungan yang memanfaatkan prinsip turunan dari persamaan atau regresi model parabolik yang sudah dihitung sebelumnya. Berdasarkan output dari MATLAB, titik optimal pada database yang sudah bersih dengan item rice, paddy berada di 2335,92 mm/tahun yang dapat menghasilkan panen maksimum di angka 3,02 Ton/ha.

6.4 Keterbatasan Model

Terdapat beberapa keterbatasan yang perlu diperhatikan dalam interpretasi hasil analisis ini:

- A. **Model univariat** : Model hanya menggunakan satu variabel prediktor (curah hujan), sementara hasil panen dipengaruhi oleh banyak faktor lain seperti kualitas tanah, penggunaan pupuk, teknologi irigasi, varietas tanaman, dan kebijakan pertanian masing-masing negara.
- B. **Heterogenitas data multi-negara** : Dataset mencakup 101 negara dengan kondisi iklim, ekonomi, dan teknologi pertanian yang sangat berbeda. Negara dengan curah hujan sama dapat menghasilkan yield yang sangat berbeda tergantung infrastruktur pertaniannya.
- C. **Representativitas model** : Nilai R^2 yang rendah (0,04) menunjukkan bahwa model parabolik hanya mampu menjelaskan 4% variasi yield, sehingga tidak disarankan untuk digunakan sebagai alat prediksi tunggal tanpa variabel tambahan.

6.5 Kesimpulan

Mini project ini berhasil mengimplementasikan regresi linier dan parabolik pada dataset nyata Crop Yield Prediction dari Kaggle, khususnya pada item tanaman Rice, paddy, dengan 2.883 baris data bersih hasil proses filtering dan cleaning outlier.

Berdasarkan hasil analisis, model parabolik terbukti lebih baik dibandingkan model linier pada seluruh metrik evaluasi ($R^2 = 0,0400$ vs $0,0239$; RMSE = $1,8949$ vs $1,9107$ ton/ha). Titik optimal curah hujan ditemukan pada $x = 2.335,92$ mm/tahun dengan prediksi hasil panen maksimum sebesar $3,02$ ton/ha.

Temuan utama proyek ini adalah bahwa nilai R^2 yang rendah bukan merupakan kegagalan model, melainkan sebuah insight berharga yang menunjukkan bahwa prediksi hasil panen secara global tidak dapat direduksi hanya pada satu variabel. Diperlukan pendekatan multivariat yang mempertimbangkan teknologi pertanian, kondisi tanah, dan faktor sosio-ekonomi untuk membangun model prediksi yang lebih akurat dan andal.

DAFTAR PUSTAKA

1. patelris. (2022). Crop Yield Prediction Dataset. Kaggle. <https://www.kaggle.com/datasets/patelris/crop-yield-prediction-dataset>
2. FAO. (2023). FAOSTAT: Crops and Livestock Products. Food and Agriculture Organization of the United Nations. <https://www.fao.org/faostat>
3. Burden, R. L., & Faires, J. D. (2011). Numerical Analysis (9th ed.). Brooks/Cole, Cengage Learning.
4. MathWorks. (2024). polyfit — Polynomial curve fitting. MATLAB Documentation. <https://www.mathworks.com/help/matlab/ref/polyfit.html>